

Blocco 6 - Aggregazioni e KPI

Cambiare granularità in modo esplicito

Relational Databases & SQL

30 min teoria + 90 min pratica

1. Rappresentazione iniziale

Partiamo da una soluzione semplice e concreta, prima di introdurre il modello generale.

Perché questo blocco

Problema didattico

Il management chiede indicatori sintetici come ricavo mensile, AOV e ticket medi. Una metrica scritta male può sembrare corretta ma contare il denominatore sbagliato o includere stati non validi.

Idea guida

Prima osserviamo una rappresentazione naturale, poi ne discutiamo i limiti e solo dopo formalizziamo.

Report manuale in una tabella riassuntiva

Situazione concreta

Si può creare a mano una tabella con ricavi mensili per canale. Il problema è che il report diventa presto scollegato dai fatti sottostanti.

mese	canale	ordini	ricavo
2025-01	web	12	8400
2025-01	sales	4	5100
2025-02	web	10	7900

Limiti della rappresentazione iniziale

- ▶ non spiega quali ordini sono inclusi;
- ▶ il denominatore può essere ambiguo;
- ▶ non si aggiorna automaticamente;
- ▶ nasconde stati esclusi e regole di calcolo.

2. Soluzione più generale

Riorganizziamo l'informazione in una forma più flessibile e controllabile.

Da report statico ad aggregazione

Principio

Con `GROUP BY` si dichiara la granularità del riepilogo e si calcolano metriche direttamente dai fatti validi.

Esempio di riorganizzazione

```
SELECT date_trunc('month', order_date)::date AS month,  
       channel, sum(gross_revenue) AS revenue  
FROM order_revenue  
WHERE status NOT IN ('cancelled', 'refunded')  
GROUP BY month, channel;
```

Processo di trasformazione

- 1 definire popolazione;
- 2 scegliere metrica e denominatore;
- 3 scegliere granularità;
- 4 applicare filtri prima dell'aggregazione;
- 5 controllare totali e conteggi.

Analogia o caso esplicativo

Dire “media voti” non basta: media per studente, per esame, per corso o per appello? Si includono assenti e ritirati? Lo stesso vale per un KPI: la formula è solo l'ultima parte della definizione.

3. Formalizzazione

Diamo un nome preciso ai concetti emersi dall'esempio.

Formalizzazione: aggregazione

- ▶ GROUP BY: una riga per gruppo;
- ▶ WHERE: filtro pre-aggregazione;
- ▶ HAVING: filtro sui gruppi;
- ▶ sum, count, avg;
- ▶ KPI come formula più popolazione e denominatore.

- ▶ **Popolazione:** righe ammesse nel calcolo.
- ▶ **Granularità:** una riga per mese, paese, segmento o categoria.
- ▶ **Denominatore:** cosa si conta o si media.
- ▶ **WHERE:** filtro prima dell'aggregazione.
- ▶ **HAVING:** filtro sui gruppi aggregati.

Come riconoscere una buona soluzione

- ▶ il KPI è definito in parole prima del codice;
- ▶ la granularità del risultato è leggibile dalle colonne in `GROUP BY`;
- ▶ denominatore e stati inclusi sono espliciti;
- ▶ i controlli confermano che il join non ha duplicato i fatti.

4. Esempio guidato

Applichiamo il modello generale a un caso piccolo, leggendo ogni passaggio.

Esempio: situazione iniziale

Domanda o frase di dominio

Domanda: “Ricavo mensile per canale sugli ordini non cancellati e non rimborsati.”

Esempio: ragionamento

- ▶ popolazione: ordini validi;
- ▶ data: `order_date`;
- ▶ granularità: mese e canale;
- ▶ misura: somma di `gross_revenue`.

Esempio completo: ricavo mensile

```
SELECT date_trunc('month', order_date)::date AS month,  
       channel,  
       round(sum(gross_revenue), 2) AS revenue  
FROM order_revenue  
WHERE status NOT IN ('cancelled', 'refunded')  
GROUP BY month, channel  
ORDER BY month, channel;
```

Errori frequenti da prevenire

- ▶ contare righe di dettaglio quando si vogliono contare ordini;
- ▶ non dichiarare stati inclusi ed esclusi;
- ▶ usare `HAVING` al posto di `WHERE`;
- ▶ calcolare media per riga quando serve media per ordine;
- ▶ non controllare il totale prima e dopo un join.

5. Pratica guidata

Ripetiamo lo stesso processo su un problema diverso: rappresentazione iniziale, limiti, riorganizzazione, soluzione.

Esercitazione: problema informale

Contesto

Il team direzione vuole una pagina KPI: ricavo per mese e canale, ricavo per paese, AOV per segmento, quantità e ricavo per categoria prodotto, ticket medi.

Esercitazione: specifica corretta

- ▶ input: viste e tabelle del dataset training;
- ▶ output: query aggregate con nome KPI, popolazione, granularità e ordinamento;
- ▶ vincolo: escludere ordini cancellati e rimborsati quando si parla di vendita valida;
- ▶ vincolo: usare HAVING solo per filtri su gruppi aggregati.

Esercitazione: definizione della soluzione

- ① creare prima query semplici per ogni KPI;
- ② aggiungere GROUP BY solo dopo aver definito la riga finale;
- ③ usare FILTER per conteggi condizionali di stati;
- ④ validare con conteggi di ordini e somme totali.

Implementazione completa: AOV per segmento (1/2)

```
SET search_path TO training;

SELECT date_trunc('month', order_date)::date AS month,
       channel,
       round(sum(gross_revenue), 2) AS revenue
FROM order_revenue
WHERE status NOT IN ('cancelled', 'refunded')
GROUP BY month, channel
ORDER BY month, channel;

SELECT c.country,
       count(DISTINCT r.order_id) AS orders,
       round(sum(r.gross_revenue), 2) AS revenue
FROM order_revenue r
JOIN customers c ON c.customer_id = r.customer_id
WHERE r.status NOT IN ('cancelled', 'refunded')
GROUP BY c.country
ORDER BY revenue DESC;
```

Implementazione completa: AOV per segmento (2/2)

```
SELECT c.segment,
       count(*) AS valid_orders,
       round(sum(r.gross_revenue), 2) AS revenue,
       round(avg(r.gross_revenue), 2) AS avg_order_value
FROM order_revenue r
JOIN customers c ON c.customer_id = r.customer_id
WHERE r.status NOT IN ('cancelled', 'refunded')
GROUP BY c.segment
HAVING count(*) >= 2
ORDER BY revenue DESC;

SELECT channel,
       count(*) FILTER (WHERE status = 'completed') AS completed_orders,
       count(*) FILTER (WHERE status = 'shipped') AS shipped_orders,
       count(*) FILTER (WHERE status = 'pending') AS pending_orders
FROM orders
GROUP BY channel
ORDER BY channel;
```

Esercitazione: organizzazione dei 90 minuti

- ▶ 15 min definizione KPI;
- ▶ 25 min ricavo mensile e per canale;
- ▶ 20 min AOV e denominatori;
- ▶ 20 min categorie prodotto e ticket;
- ▶ 10 min controlli e confronto.

- ▶ confrontare almeno due soluzioni quando esistono alternative;
- ▶ chiedere quali assunzioni cambierebbero la soluzione;
- ▶ separare errori di sintassi, errori di modello ed errori di interpretazione.

- ▶ una metrica senza denominatore dichiarato è ambigua;
- ▶ GROUP BY cambia la granularità: va letto come una decisione di business;
- ▶ un risultato aggregato corretto si difende con controlli intermedi.